Détection de la Rétinopathie Diabétique par Réseau de Neurones Convolutifs

Une investigation pour reproduire et affiner les approches de diagnostic par IA

Bezet Camille, Martins Soares Flavio, Kenmogne Loïc, Brasa Franklin
ING3 IA A, groupe 6, projet 5
À l'attention de M.Djahid ABDELMOUMENE et Pr.Mai khuong NGUYEN VERGER

La Rétinopathie Diabétique : Une menace silencieuse pour la vision

La RD est l'une des principales causes de cécité au sein de la population en âge de travailler. Elle est une complication du diabète touchant plus de 425 millions de personnes dans le monde.

40%
des patients diabétiques aux États-Unis avaient développé une rétinopathie en 2018.

1.6 millions
de décès causés par le diabètes en 2016 (OMS).

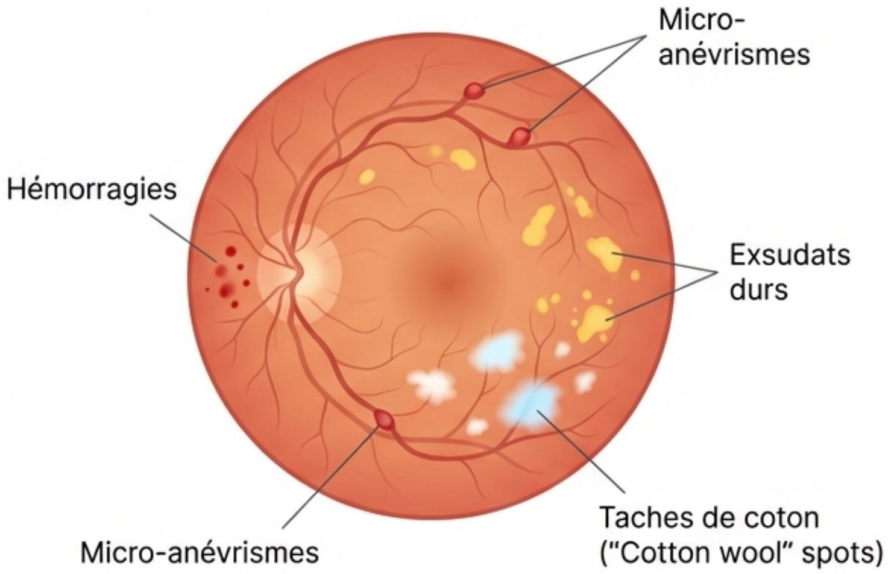

L'impératif du diagnostic précoce pour préserver la vue

Prévenir l'irréversible
La détection précoce, au stade Non Proliferatif (RDNP), permet un traitement opportun avant que la cécité ne devienne permanente.

Identifier les premiers signes
Les anomalies comme les micro-anévrismes, les hémorragies et les exsudats sont des indicateurs précoces visibles via la photographie du fond d'œil.

L'enjeu
Automatiser l'examen de la rétine pour un dépistage à grande échelle.

L'enjeu n'est pas seulement technique, il s'agit de fournir un outil capable d'initier une prise en charge médicale au moment le plus opportun pour des millions de patients.

L'évolution des outils de diagnostic: De l'analyse manuelle au Deep Learning

Approches morphologiques

Analyse d'intensité, extraction de caractéristiques manuelles (couleur, forme).

Exemples: détection d'exsudats du analyse du canal vert.

Machine Learning classique

Utilisation de modèles comme les Réseaux de Neurones Artificiels (ANN) ou les SVM.

Limitation: Nécessite encore une ingénierie des caractéristiques.

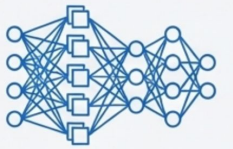

Deep learning (CNN)

Apprentissage automatique et hiérarchique des caractéristiques directement depuis l'image brute.

Avantage clé: Capacité à détecter des motifs complexes (lésions, vaisseaux) sans intervention humaine.

Notre mission : Reproduire et évaluer l'approche CNN de Abed et al. (2020)

Objectif principal

Concevoir et implémenter un système de détection de la RD en s'appuyant sur l'architecture CNN et le pipeline de prétraitement proposés dans l'article de référence.

Grandes étapes à suivre

1. Reproduire fidèlement l'architecture du réseau et le prétraitement en utilisant un environnement moderne (TensorFlow/Keras).
2. Évaluer les performances du modèle sur les trois jeux de données publics utilisés dans l'étude (DIARETDBO, DIARETDB1, DRIMDB).
3. Comparer nos résultats à ceux publiés pour valider la méthode.
4. Explorer des extensions pour tester la robustesse du modèle.

Les données au cœur de notre projet

Dataset	Nombre d'images	Résolution	Objectif principal	Annotations clés
DiaretDB0	130	1500 x 1152	**Détection** des lésions	Coordonnées des lésions (MA, hémorragies, exsudats)
DiaretDB1	89	1500 x 1152	**Détection** des lésions	Coordonnées des lésions (toutes les images sont pathologiques)
DRIMDB	216	570 x 760	**Évaluation** de la **qualité** des images	Labels de qualité de l'image (bonne, mauvaise)

Outils et environnement

Langage : Python

Framework : TensorFlow/Keras

Env : Google colab / Jupyter notebook

Bibliothèques: scikit-learn, matplotlib, OpenCV

Préparation des images : Un pipeline de prétraitement pour révéler les détails

1 → 2 → 3 → 4 → 5

Chargement & Conversion

BGR -> RGB pour standardiser l'espace colorimétrique.

Recadrage Automatique

crop_image_from_gray() pour supprimer les bordures noires.

Redimensionnement

resize (224, 224) pour uniformiser la taille des entrées.

Amélioration du contraste (CLAHE)

Application sur le canal de luminance (L) pour rehausser les détails.

Normalisation

Division par 255.0 pour mettre à l'échelle les pixels entre [0, 1].

Chaque étape est essentielle pour nettoyer, standardiser et améliorer les données visuelles, permettant au CNN de se concentrer sur les caractéristiques pathologiques pertinentes.

L'architecture du modèle CNN: Une structure légère et ciblée

Notre modèle, implémenté en Keras, suit la structure proposée par Abed et al. : un réseau séquentiel conçu pour être efficace sur la détection des RD.

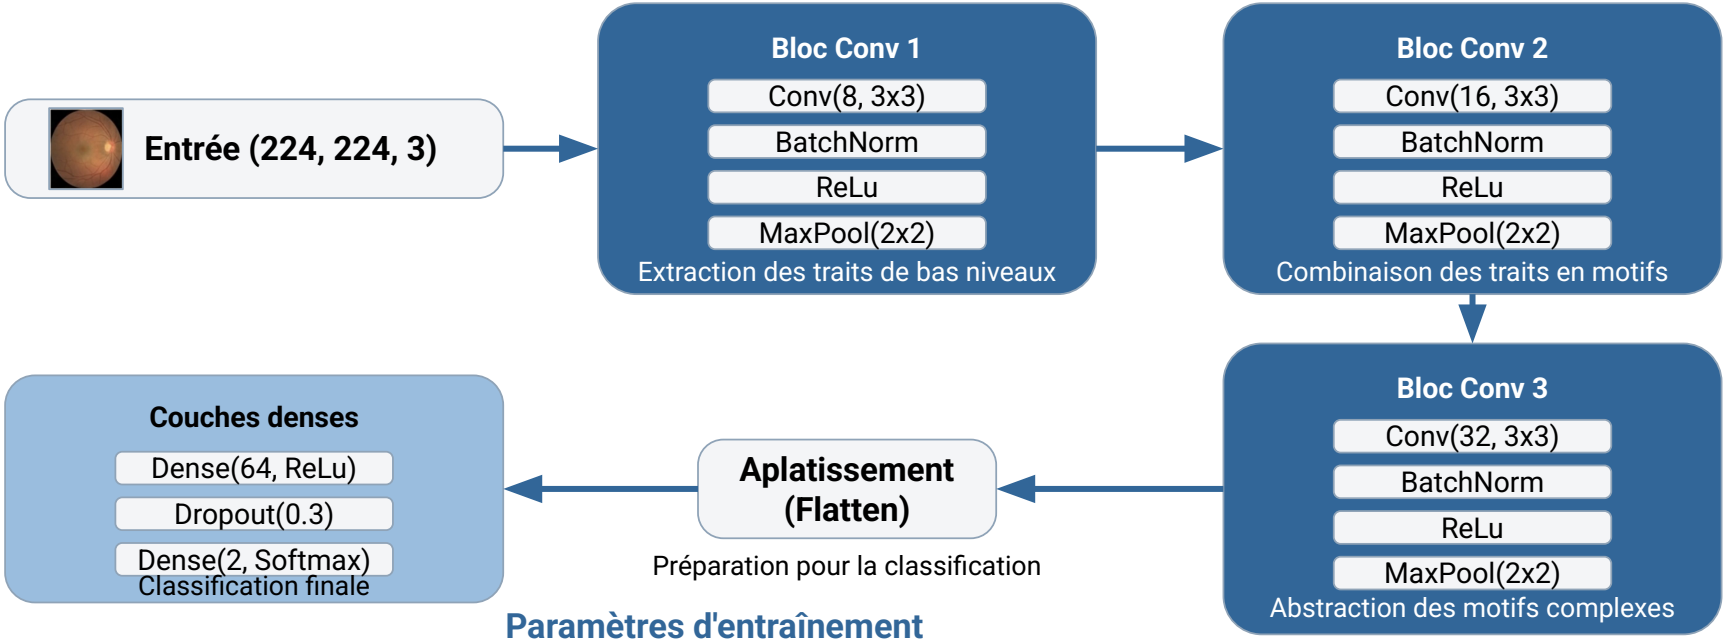

Paramètres d'entraînement

- Optimiseur: SGD (lr = 0.01, momentum = 0.9)
- Fonction de coût: Categorical crossentropy

Premiers résultats : Nous avons reproduit les performances de l'étude de référence

Le modèle a été entraîné et évalué sur les trois jeux de données, en utilisant une répartition de 80% pour l'entraînement et 20% pour le test.

Dataset	Nombre d'epochs	Validation accuracy Abed et al. (2020)	Validation accuracy projet
DIARETDB0	1	62,67%	**84.6%**
	13	100%	84.6%
	20	100%	84.62%
DIARETDB1	1	57,9%	**100%**
	13	99,89%	**100%**
	20	99,1%	**100%**
DRIMDB	1	68%	40.91%
	13	95,1%	43.2%
	20	100%	43.2%

Analyse :
Notre implémentation atteint des **performances comparables**, et dans le cas de **DIARETDB1**, **supérieures** à celles rapportées dans l'étude originale.
Ce succès ***apparent*** validerait notre pipeline technique.

Au-delà des chiffres : Une analyse critique des données révèle un biais fondamental

Problème: Des scores de précision élevés peuvent être trompeurs si les données d'évaluation sont biaisées. Notre analyse a révélé des limitations critiques dans les datasets.

DIARETDB0: Taille très limitée (130 images) et contient très peu d'images vraiment 'saines', créant un fort déséquilibre.

DIARETDB1: Ne contient **aucune** image saine. Un modèle qui prédit toujours 'pas sain' obtient une précision de 100%.

DRIMDB: Est conçu pour évaluer la ***qualité*** de l'image, et non la présence de pathologie.

Conclusion: La tâche de classification binaire 'sain' / 'pas sain' est fondamentalement faussée sur ces datasets. Les résultats ne mesurent pas une réelle capacité de diagnostic, mais potentiellement un apprentissage du biais intrinsèque des données.

Le pivot : D'une tâche de classification simple à un test de détection spécifique

La problématique

Comment évaluer de manière fiable notre modèle malgré les limitations de datasets ?

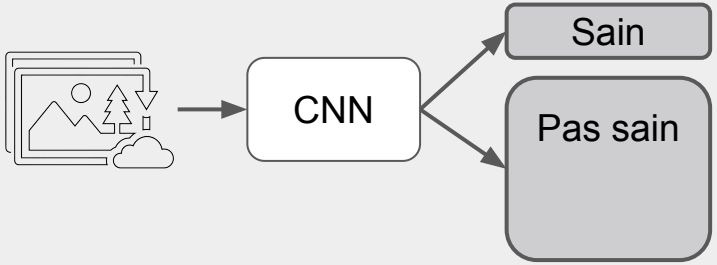

Notre solution

Reformuler le problème. Au lieu d'une classification binaire "sain/malade" ambiguë, nous avons défini une nouvelle tâche :

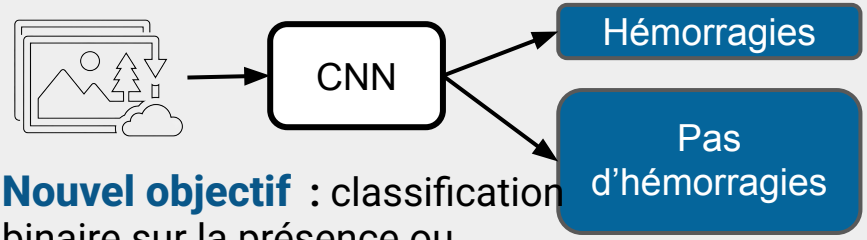

Nouvel objectif : classification binaire sur la présence ou absence d'hémorragies sur DIARETDB0.

Pourquoi cette approche est plus robuste

1. **Labels fiables**: les hémorragies sont clairement annotées dans les fichiers, permettant un étiquetage précis et objectif.
2. **Jeu de données plus équilibré**: La tâche oppose 29 images avec hémorragies à 101 images sans, créant un scénario de classification plus réaliste.
3. **Véritable test d'apprentissage**: Le modèle doit apprendre à reconnaître une signature visuelle spécifique, et non simplement la classe majoritaire.

Résultats de la détection d'hémorragies: Un équilibre délicat entre apprentissage et surapprentissage

Le même pipeline et la même architecture CNN ont été utilisés pour la nouvelle tâche de détection d'hémorragies sur DIARETDB0.

Nombre d'epochs	Accuracy (test set)	Loss (test set)	Interprétation
1	73.08%	0.69	Le modèle commence à peine son apprentissage.
13	**76.92%**	**0.59**	**Performance optimale. Le modèle a convergé vers un bon équilibre.**
20	69.23%	0.67	Début de surapprentissage. Les performances se dégradent.

Synthèse: cette expérience ciblée révèle que le modèle atteint son pic de performance à 13 epochs avant de surapprendre. Cela démontre l'importance capitale d'un arrêt précoce de l'entraînement, un insight masqué par la tâche de classification initiale.

Visualisation du surapprentissage : Quand le modèle mémorise au lieu de généraliser

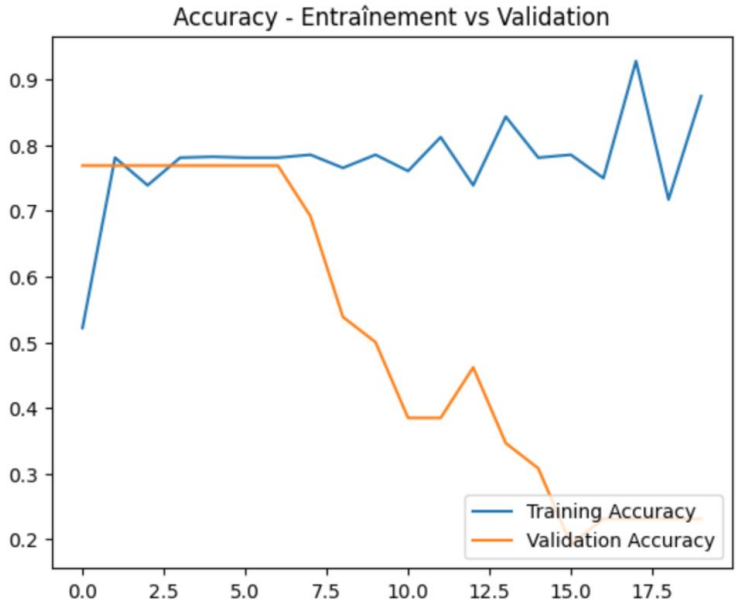

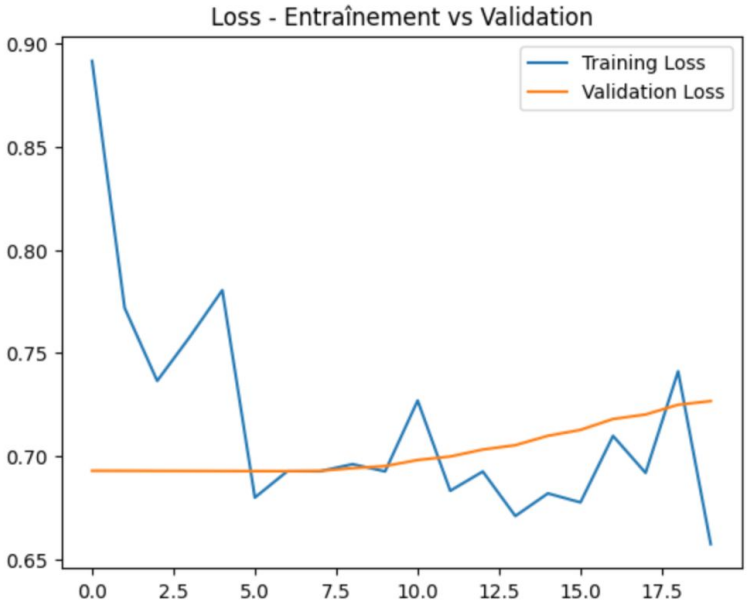

Conclusion visuelle : La divergence nette entre les performances d'entraînement et de validation est la signature visuelle du surapprentissage. Le modèle devient 'trop bon' sur les données qu'il a déjà vues, au détriment de sa performance sur de nouvelles images.

Conclusion: Au-delà de la réplication, une feuille de route pour une évaluation rigoureuse

Résumé de notre projet

Validation réussie
Nous avons reproduit l'architecture de Abed et al., confirmant la viabilité de leur approche.

Découverte critique
Notre investigation a mis en lumière des biais dans les jeux de données, rendant la tâche de classification "sain/malade" peu fiable pour une évaluation de performance honnête.

Changement d'approche
En pivotant vers une tâche de détection de lésion spécifique (hémorragies), nous avons pu tester le modèle décrit et le valider, tout en mettant en lumière le phénomène de surapprentissage.

L'apport principal :
Ce projet démontre que la valeur d'un modèle d'IA ne réside pas seulement dans son architecture, mais aussi dans la rigueur de la formulation du problème et la qualité des données.

Merci de nous avoir écouté !

Bezet Camille, Martins Soares Flavio, Kenmogne Loïc, Brasa Franklin
ING3 IA A, groupe 6, projet 5
À l’attention de M.Djahid ABDELMOUMENE et Pr.Mai khuong NGUYEN VERGER

Bibliographie

[1] Tahira Nazir, Aun Irtaza, Zain Shabbir, Ali Javed, Usman Akram, Muhammad Tariq Mahmood, Diabetic retinopathy detection through novel tetragonal local octa patterns and extreme learning machines, Artificial Intelligence in Medicine, Volume 99, 2019, 101695, ISSN 0933-3657, https://doi.org/10.1016/j.artmed.2019.07.003

[2] John Elflein, Diabetes - Statistics & Facts, Health & Pharmaceuticals , Sep 12, 2019, https://www.statista.com/topics/1723/diabetes/

[3] Wang W, Lo ACY. Diabetic Retinopathy: Pathophysiology and Treatments. Int J Mol Sci. 2018;19(6):1816. Published 2018 Jun 20. doi:10.3390/ijms19061816.

[4] S.A.G. Naqvi, M.F. Zafar, I. ul Haq, Referral system for hard exudates in eye fundus, Comput. Biol. Med. 64 (2015) 217–235, http://dx.doi.org/10.1016/j.compbiomed.2015.07.003

[5] W.M.D.W. Zaki, M.A. Zulkifley, A. Hussain, W.H.W.A. Halim, N.B.A. Mustafa,L.S. Ting, Diabetic retinopathy assessment: towards an automated system, Biomed. Signal Process. Control 24 (2016) 72–82.

[6] A. Sopharak, B. Uyyanonvara, S. Barman, T.H. Williamson, Automatic detection of diabetic retinopathy exudates from non-dilated retinal image using mathematical morphology methods, Comput. Med. Imaging Graph. 32(8) (2008) 720–727.

[7] NIDHAL K. EL ABBADI, ENAS HAMOOD AL- SAADI, Automatic Early Diagnosis of Diabetic Retinopathy Using Retina Fundus Images, EUROPEAN ACADEMIC RESEARCH, Vol. II, Issue 9/ December 2014

[8] L. Giancardo, F. Meriaudeau, T.P. Karnowski, Y. Li, S. Garg, K.W. Tobin Jr., E.Chaum, Exudate-based diabetic macular edema detection in fundus images using publicly available datasets, Med. Image Anal. 16 (1) (2012) 216–226.

[9] C.I. Sánchez, M. García, A. Mayo, M.I. López, R. Hornero, Retinal image analysis based on mixture models to detect hard exudates, Med. Image Anal. 13 (4)(2009) 650–658.

[10] B_alint BORSOS, L_aszl_o NAGY, David ICL_ANZAN and L_aszl_o SZIL_AGYI, " Automatic detection of hard and soft exudates from retinal fundus images", Acta Univ. Sapientiae, Informatica 11, 1 (2019) 65{79}.

[11] S. Bourouis, A. Zaguia, N. Bouguila, Hybrid statistical framework for diabetic retinopathy detection,in: International Conference Image Analysis and Recognition, Springer, 2018, pp. 687–694.

[12] P. Prentasic, S. Loncaric, Detection of exudates in fundus photographs using convolutional neural networks, 2015 9th International Symposium on Image and Signal Processing and Analysis (ISPA) (2015) 188–192, http://dx.doi.org/10.1109/ISPA.2015.7306056

[13] Parham Khojasteh, Behzad Aliahmad, Dinesh Kant Kumar , A novel color space of fundus images for automatic exudates detection. Biomed. Signal Process. Control. 49: 240-249 (2019)

[14] P. Khojasteh, L.A.P. Júnior, T. Carvalho, E. Rezende, B. Aliahmad, J.P. Papa, D.K.Kumar, Exudate detection in fundus images using deeply-learnable features, Comput. Biol. Med. 104 (2019) 62–69, http://dx.doi.org/10.1016/j.compbiomed.2018.10.031

[15] M.H. Abed, L.A.N. Muhammed, S.H. Toman, Diabetic Retinopathy Diagnosis based on Convolutional Neural Network, arXiv preprint arXiv:2008.00148, 2020. https://arxiv.org/abs/2008.00148