AI Based Image Processing

Projet 5

À l'attention de M.Djahid ABDELMOUMENE et Pr.Mai khuong NGUYEN VERGER

BEZET Camille

BRASA Franklin

KENMOGNE Loïc

MARTINS SOARES Flavio

ING3 IA A, groupe 6

Le 3 Décembre 2025

Sommaire

Introduction 4
Contexte et positionnement 5
La rétinopathie diabétique (RD) 5
Mécanisme de la Maladie 5
Stades et Signes Cliniques 5
L'enjeu du diagnostic précoce 6
Revue des méthodes existantes 7
Méthodes basées sur les concepts morphologiques 7
Méthodes Basées sur l'Apprentissage Automatique (Machine Learning) 8
Méthodes Basées sur l'Apprentissage Profond (Deep Learning) 8
L'apport des réseaux de neurones convolutifs 9
Objectif de ce projet 9
Données utilisées 10
Présentation des jeux de données 10
Objectif des datasets 10
DiaretDB0 11
Caractéristiques techniques 11
Limites spécifiques 11
DiaretDB1 12
Caractéristiques techniques 12
Limites spécifiques 13
DRIMDB 13
Caractéristiques techniques 13
Limites spécifiques 14
Démarche méthodologique 14
Présentation générale de l'approche 14
Description du pipeline 15
Prétraitement des images 15
Chargement et conversion des couleurs 15
Suppression des bordures sombres 15
Redimensionnement de l'image 15
Amélioration du contraste par CLAHE 16
Normalisation des pixels 16
Architecture CNN 16
Objectif du modèle 16
Architecture détaillée 16
Conclusion sur le choix d'architecture 18
Entraînement & évaluation 18
Objectif expérimental 18

Chargement et prétraitement des données..... 18
Séparation entraînement / test..... 19
Évaluation et métriques..... 19
Comparaison avec le papier..... 19
Interprétation..... 20
Outils et environnement technique..... 21
Extensions possibles et améliorations..... 22
Classification selon le label “hémorragies”..... 22
Contexte..... 22
Mise en place du code..... 23
Entraînement & évaluation..... 23
Utilisation de l’IA..... 24
Dans le code..... 24
Dans le rapport..... 25
Conclusion..... 25
Bibliographie..... 27

Introduction

La Rétinopathie Diabétique (RD) est une complication oculaire majeure du diabète, touchant plus de 425 millions de personnes dans le monde. Elle est considérée comme l'une des principales causes de cécité au sein de la population en âge de travailler. La maladie résulte d'un niveau de sucre anormal dans les vaisseaux rétiniens, conduisant à des anomalies comme les micro-anévrismes et les hémorragies.

L'enjeu principal est le diagnostic précoce au stade de Rétinopathie Diabétique Non Proliférative (RDNP), indispensable pour prévenir la cécité irréversible et permettre un traitement opportun.

Alors que les méthodes traditionnelles reposaient sur des concepts morphologiques ou des techniques de Machine Learning nécessitant une ingénierie manuelle des caractéristiques, l'Apprentissage Profond (Deep Learning) a révolutionné ce domaine. Les Réseaux de Neurones Convolutifs (CNN) sont particulièrement efficaces car ils apprennent automatiquement les caractéristiques hiérarchiques (des bords aux lésions) à partir des données brutes, permettant des diagnostics plus rapides et précis.

L'objectif principal de ce projet est de concevoir et d'implémenter un système automatique de détection de la RD à partir d'images de fond d'œil. Nous nous basons sur l'approche de Abed et al. (2020) [15], en reproduisant fidèlement l'architecture CNN proposée et le pipeline de prétraitement par CLAHE. Notre travail vise à évaluer de manière critique les performances de ce modèle sur des datasets publics et à proposer des axes d'amélioration.

Contexte et positionnement

La rétinopathie diabétique (RD)

La Rétinopathie Diabétique (RD), ou Diabetic Retinopathy (DR) en anglais, est l'une des maladies oculaires les plus courantes. C'est une maladie qui touche les personnes souffrant de diabète depuis de nombreuses années. Elle est considérée comme l'une des principales causes de cécité au sein de la population en âge de travailler [1].

Selon l'Organisation Mondiale de la Santé environ 1.6 millions de personnes sont décédées à cause du diabète en 2016 [2]. Plus de 425 millions de personnes vivent quotidiennement avec cette maladie dans le monde, dont 29.1 millions aux États-Unis. En 2018, environ 40% de ces patients avaient développé une rétinopathie diabétique [1].

Mécanisme de la Maladie

La RD survient en raison d'un niveau de sucre anormal dans les vaisseaux sanguins de la rétine. La fonction rétinienne nécessite la présence de tissus sanguins rétiniens, où ces tissus sont répartis.

Les conditions anormales du taux de sucre dans le sang des vaisseaux rétiniens entraînent initialement [3]:

1. Une augmentation de la perméabilité vasculaire.
2. La formation de plaques de lipoprotéines.
3. Une occlusion capillaire dans la vascularisation rétinienne.

L'accumulation d'exsudats de lipoprotéines mène à l'œdème maculaire. Cela affecte négativement la vision et est considéré comme un signe précoce de la rétinopathie diabétique.

Stades et Signes Cliniques

La rétinopathie diabétique est divisée en deux stades principaux [3] :

1. La Rétinopathie Diabétique Non Proliférative (RDNP ou NPDR) : c'est le stade précoce de la maladie. Durant ce stade, on observe une perméabilité vasculaire accrue et une occlusion capillaire.
2. La Rétinopathie Diabétique Proliférative (RDP ou PDR).

Les pathologies rétiniennes (ou anomalies) qui peuvent être détectées par la photographie du fond d'œil pour diagnostiquer la RD à un stade précoce comprennent :

- Les micro-anévrismes,
- Les hémorragies,
- Les exsudats durs (par exemple, des plaques de lipoprotéines),
- Les tâches de coton (cotton wool spots).

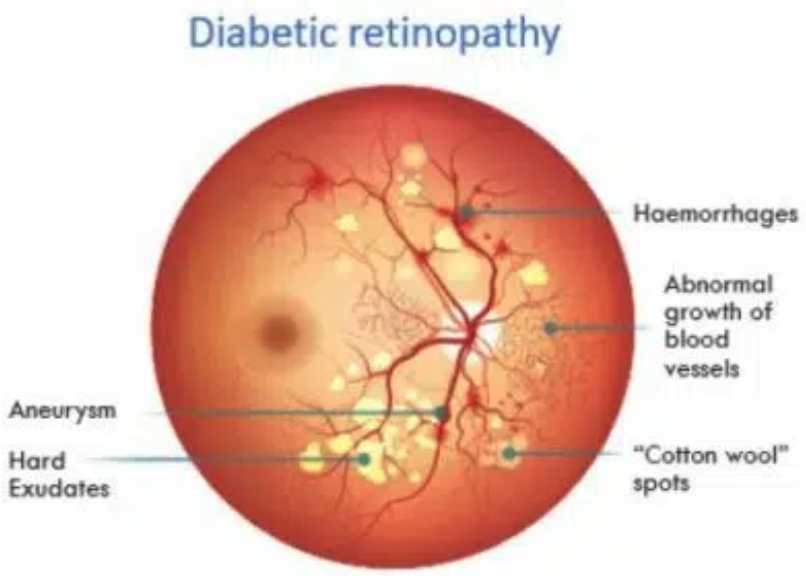

Fig 1. Schéma des pathologies rétiniennes liées à la RD (source : The Fred Hollows Foundation)

Ces anomalies peuvent entraîner une cécité non réversible et une déficience visuelle. Pour le diagnostic, l'examen continu de la rétine est nécessaire. Les outils informatiques, tels que ceux utilisant la technologie de la vision par ordinateur et les réseaux neuronaux convolutifs (CNN), sont utilisés pour l'examen automatique et la classification des images rétiniennes comme saines ou malsaines.

L'enjeu du diagnostic précoce

L'enjeu principal du diagnostic précoce est la prévention des conséquences irréversibles de cette maladie :

- Prévenir la cécité : le diagnostic de la RD, surtout à un stade précoce, peut prévenir ses effets pour beaucoup de patients, notamment la cécité. La détection de la maladie à un stade précoce est particulièrement importante pour pouvoir traiter le patient.
- Traitement opportun : la détection précoce permet au patient de recevoir le traitement au moment approprié (proper time).

- Identification des anomalies initiales : le stade précoce de la RD est la Rétinopathie Diabétique Non Proliférative (RDNP). À ce stade, certaines anomalies rétiniennes peuvent déjà être détectées par la photographie du fond d'œil, comme les micro-anévrismes, les hémorragies et les exsudats durs. Ces anomalies sont des signes précoces qui, s'ils ne sont pas traités, peuvent conduire à une cécité non réversible et à une déficience visuelle.

En résumé, comme la RD est une maladie populaire et qu'elle peut entraîner la cécité, un diagnostic précoce est essentiel pour éviter la perte de vision chez de nombreux patients.

Revue des méthodes existantes

Méthodes basées sur les concepts morphologiques

Historiquement et dans les travaux antérieurs, plusieurs méthodes se sont concentrées sur l'analyse des caractéristiques visibles de la maladie, souvent appelées concepts morphologiques :

- **Détection morphologique et analyse d'intensité** : S.A.G. Naqvi et al, W.M.D.W. Zaki et al et A. Sopharak ont conçu des modèles de détection automatique basés sur le concept morphologique à travers l'analyse de l'intensité de la rétine pour détecter spécifiquement les exsudats. [4][5][6]
- **Algorithmes de comparaison simple** : une approche a suggéré un diagnostic précoce basé sur la détection d'indications anormales (exsudats, saignements, diamètre et tortuosité des vaisseaux sanguins) en utilisant un algorithme de comparaison simple avec des images du fond d'œil. Cette méthode a atteint une précision de 100% sur un jeu de 100 patients (dont 10 souffraient de problèmes oculaires liés au diabète). [7]
- **Analyse du canal vert** : certains travaux ont utilisé le canal vert de l'espace couleur RGB et l'intensité de ce canal à partir des images rétiniennes pour détecter les exsudats. [8]
- **Modélisation statistique et clustering** : une technique a été proposée basée sur un modèle statistique et le clustering pour le seuillage dynamique des pixels d'exsudats. [9]

Méthodes Basées sur l'Apprentissage Automatique (Machine Learning)

Les systèmes plus avancés exploitent l'apprentissage automatique (Machine Learning) pour améliorer la reconnaissance des caractéristiques :

- **Réseaux Neuronaux Artificiels (ANN)** : des systèmes automatiques ont été présentés pour la détection des exsudats durs et mous (soft and hard exudates). Ces systèmes utilisaient différentes étapes de prétraitement (segmentation et normalisation) puis appliquaient un Réseau Neuronal Artificiel (ANN) pour identifier les pixels appartenant aux exsudats. [10]
- **Cadre statistique hybride** : un cadre statistique hybride a été proposé pour la détection de la RD, combinant le noyau probabiliste basé sur la machine à vecteurs de support (SVM-based kernel) avec des distributions de Dirichlet mises à l'échelle. [11]

Méthodes Basées sur l'Apprentissage Profond (Deep Learning)

Les techniques d'apprentissage profond (Deep Learning) ont obtenu des résultats très prometteurs (promising accuracy) dans les problèmes de vision par ordinateur et, en particulier, dans l'analyse d'images médicales, surpassant souvent les autres techniques de vision par ordinateur.

Le CNN est une des méthodes clés du Deep Learning et est fortement influencé par le système visuel humain. C'est une méthode privilégiée pour le diagnostic automatique.

- **Détection d'exsudats via CNN** : P. Prentasic and S. Loncaric ont conçu un réseau neuronal convolutif (CNN) de dix couches qu'ils ont entraîné spécifiquement pour détecter les exsudats dans les images rétiniennes de couleur RGB. [12]
- **Analyse d'espaces de couleurs** : d'autres recherches (Parham Khojasteh et al) ont suggéré un nouveau modèle d'espace couleur pour les images du fond d'œil pour la détection automatique des exsudats et ont utilisé des CNN pour évaluer la précision de performance de différents modèles d'espace couleur. Une précision de 89,1% a été obtenue pour le modèle CNN dans ce contexte. [13][14]

Ces résultats indiquent que l'apprentissage profond et les réseaux neuronaux convolutifs (CNN) sont une direction prometteuse pour le diagnostic diabétique automatique basé sur les images rétiniennes couleur.

L'apport des réseaux de neurones convolutifs

La principale force des CNN réside dans leur capacité à analyser des images de fond d'œil complexes sans nécessiter d'ingénierie manuelle des caractéristiques (ou handcrafted features).

Contrairement aux anciennes méthodes qui s'appuyaient sur des filtres de traitement d'image spécifiques, les CNN apprennent automatiquement les caractéristiques hiérarchiques à partir des données brutes. Les CNN sont conçus pour apprendre automatiquement les hiérarchies spatiales de caractéristiques à partir des données d'entrée. Les couches initiales extraient des caractéristiques de bas niveau comme les bords, les textures et les formes de base, tandis que les couches profondes ou finales (couches complètement connectées) produisent des représentations abstraites de haut niveau des objets, comme les lésions ou les anomalies des vaisseaux.

Cette capacité d'apprentissage profond permet aux CNN de détecter et d'extraire des caractéristiques complexes telles que les microanévrismes, les hémorragies et les exsudats.

L'utilisation des CNN mène à des résultats diagnostiques remarquables en termes de vitesse et de précision, améliorant directement la prise en charge des patients.

L'apport des CNN ne se limite pas à la classification binaire (RD présente ou absente). Ils sont efficaces pour la classification multi-classes, c'est-à-dire l'évaluation du niveau de gravité de la RD (par exemple, classification en 4 ou 5 stades). Un modèle comme RSG-Net a atteint une précision de 99,36 % pour la classification en 4 stades de gravité.

Objectif de ce projet

L'objectif principal de ce projet est de concevoir et d'implémenter un système automatique de détection de la rétinopathie diabétique (RD) à partir d'images de fond d'œil, en s'appuyant sur les travaux proposés dans l'article "Diabetic Retinopathy Diagnosis based on Convolutional Neural Network" de Abed et al. (2020) [15]. L'approche décrite dans ce papier repose sur un réseau de neurones convolutifs (CNN) personnalisé, entraîné à partir de trois jeux de données publics (DIARETDB0, DIARETDB1, DRIMDB) et précédé d'une phase de prétraitement visant à améliorer le contraste des images via la méthode CLAHE (Contrast-Limited Adaptive Histogram Equalization).

Dans un premier temps, il s'agira de reproduire fidèlement l'architecture CNN décrite par les auteurs, comprenant trois blocs convolution, batch normalization, ReLU, max pooling, suivis de deux couches entièrement connectées dont une avec une fonction softmax pour la classification binaire (rétine saine / pathologique). L'objectif est d'évaluer cette architecture à l'aide d'un environnement de développement moderne **(ex. : PyTorch ou TensorFlow)**, en comparant les performances obtenues avec celles présentées dans l'étude.

Dans un second temps, le projet pourra être étendu selon plusieurs axes :

- tester le modèle de classification selon d'autres labels,
- tester le modèle sur une classification multi-labels.

Ce travail vise donc non seulement à valider les résultats obtenus dans l'étude, mais également à proposer des pistes d'amélioration concrètes pour un système de diagnostic assisté par l'IA, robuste et généralisable à des conditions réelles.

Données utilisées

Présentation des jeux de données

Les datasets DIARETDB0, DIARETDB1 et DRIMBD sont des bases de données d'imagerie rétinienne utilisées pour la recherche sur la détection automatique de la rétinopathie diabétique (RD).

Objectif des datasets

Le but de ces datasets est de fournir un ensemble standardisé d'images du fond d'œil permettant :

- la détection de lésions caractéristiques de la rétinopathie diabétique,
- l'évaluation des performances d'algorithmes d'analyse d'image ou de modèles de deep learning,
- la comparaison entre différentes méthodes de détection.

DiaretDB0

Caractéristiques techniques

Élément	Détail
Nombre d'images	130 images RGB
Résolution	1500 × 1152 pixels
Format	JPEG non compressé
Type	Images du fond d'œil (rétinographie couleur)
Annotation	Effectuée par quatre experts humains
Lésions annotées	- micro-anévrismes (MA) - hémorragies - exsudats durs - exsudats cotonneux (soft)

Tab 1. Caractéristiques techniques du dataset DiaretDB0

Limites spécifiques

Malgré sa notoriété en recherche sur la rétinopathie diabétique, le dataset DIARETDB0 présente plusieurs limites majeures :

- **Taille très limitée** : le jeu contient seulement 130 images, ce qui est largement insuffisant pour entraîner des modèles profonds.
- **Peu d'images vraiment saines** : même si la documentation indique que le dataset inclut des images saines, la très grande majorité des images contiennent au moins une lésion annotée. Le déséquilibre est donc marqué entre les classes "sain" et "pathologique", rendant difficile l'apprentissage d'un classifieur robuste sur des données réelles. Cela fausse aussi l'évaluation, notamment pour le calcul des métriques sensibles aux faux positifs sur des images saines.

- **Pas de labels d'image globale** : le dataset n'indique pas explicitement si une image est "saine" ou "pas saine". Les labels globaux ne sont pas fournis. Cela oblige à dériver les labels d'image à partir des lésions détectées, ce qui introduit une incertitude sur la cohérence de l'étiquetage.

DiaretDB1

Caractéristiques techniques

Élément	Description
Nombre d'images	89 images RGB
Résolution	1500×1152 pixels
Format	PNG (compressé sans perte)
Type d'image	Couleur RGB issues de caméras de fond d'œil
Types de lésions annotées	- Micro-anévrismes (MA) - Hémorragies - Exsudats durs - Exsudats cotonneux
Type d'annotation	Coordonnées (x, y) des lésions avec type et certitude (high/low)
Fichiers d'annotation	Format .xml et .txt, selon les versions
Étiquettes d'image	Toutes les images sont pathologiques (contiennent au moins une lésion

Tab 2. Caractéristiques techniques du dataset DiaretDB1

Limites spécifiques

Malgré sa qualité et son utilité reconnue pour la recherche en ophtalmologie, le dataset DIARETDB1 présente plusieurs limites importantes :

- **Pas de segmentation pixel-par-pixel** : DIARETDB1 fournit uniquement des annotations ponctuelles (x, y) des lésions, avec un type de lésion (micro-anévrisme, exsudat, etc.) et parfois un niveau de confiance (high ou low). Il n'inclut pas de masques segmentés, ni de contours précis des lésions. Il est donc impossible d'entraîner des modèles de segmentation supervisée (ex : U-Net) sans créer artificiellement des masques.
- **Aucune image saine** : le dataset a été construit uniquement à partir d'images présentant des signes précoces de rétinopathie diabétique. Il ne contient aucune image totalement saine (même si certaines sont très peu touchées).

DRIMDB

Caractéristiques techniques

Caractéristique	Détail
Nom complet	DRIMDB (Diabetic Retinopathy Image Quality Database)
Objectif principal	Évaluation de la qualité des images du fond d'œil (pas de détection de pathologie)
Nombre d'images	216 images
Type d'image	Rétinographies couleur (RGB)
Résolution	Environ 570×760 pixels

Format d'image	PNG
Annotations disponibles	Labels globaux : good, bad, outlier (qualité d'image)

Tab 3. Caractéristiques techniques du dataset DRIMDB

Limites spécifiques

- **Spécificité du critère "qualité d'image"** : DRIMDB classe les images selon des critères subjectifs (bonne, mauvaise, outlier). Même si ces classifications sont faites par des experts, la qualité reste un critère technique, non médical. La classification ne garantit pas la présence ou l'absence de pathologies.

Démarche méthodologique

Présentation générale de l'approche

L'approche développée dans ce projet s'inscrit dans le cadre de la détection automatique de la rétinopathie diabétique (RD) à partir d'images de fond d'œil, en s'appuyant sur des techniques d'apprentissage profond, et plus précisément sur les réseaux de neurones convolutifs (CNN). L'objectif est de reproduire, puis potentiellement améliorer, l'architecture proposée dans l'article de Mohammed Hamzah Abed et al. (2020) [illegible], en adaptant l'implémentation à un environnement moderne comme TensorFlow.

Le pipeline de traitement se décompose en trois grandes étapes :

1. **Prétraitement des images,**
2. **Entraînement d'un modèle CNN ,**
3. **Évaluation des performances.**

Cette approche vise à démontrer la capacité des CNN à détecter automatiquement les signes précoces de la RD, tout en posant les bases d'améliorations futures, telles que l'intégration de la classification multi-stade ou l'ajout d'une étape de segmentation des lésions.

Cette partie du code se trouve dans le notebook nommé **"CNN-Binaire-sain/pas-sain.ipynb"**.

Description du pipeline

Prétraitement des images

Le prétraitement est une étape essentielle dans tout pipeline de classification d'images, notamment dans le cadre de l'analyse d'images médicales comme la rétinopathie diabétique. Son objectif est d'améliorer la qualité des données visuelles en supprimant les artefacts inutiles, en normalisant les dimensions et en rehaussant les contrastes afin de faciliter l'apprentissage automatique. Le code de prétraitement utilisé dans notre projet suit plusieurs étapes clés :

Chargement et conversion des couleurs

Les images sont chargées depuis leur chemin de fichier (`cv2.imread`). Une conversion de l'espace colorimétrique BGR (format OpenCV) vers RGB (standard deep learning) est effectuée avec `cv2.cvtColor(img, cv2.COLOR_BGR2RGB)`.

Cette conversion garantit la cohérence des couleurs, car les bibliothèques d'apprentissage (comme Keras ou PyTorch) s'attendent à des images en RGB.

Suppression des bordures sombres

La fonction `crop_image_from_gray` supprime les bordures noires inutiles autour de la rétine. Pour cela, elle identifie les pixels dont l'intensité (en niveau de gris) dépasse un seuil de tolérance (tol = 7) et recadre l'image sur la zone utile.

Cela permet d'éliminer les informations parasites (bordures noires fréquentes dans les photos de fond d'œil), tout en conservant uniquement la zone d'intérêt contenant la rétine.

Redimensionnement de l'image

Une fois recadrée, l'image est redimensionnée à une taille fixe IMG_SIZE x IMG_SIZE (IMG_SIZE = 224) via `cv2.resize`. Cette étape garantit l'homogénéité du jeu de données d'entrée, compatible avec les dimensions attendues par le réseau de neurones convolutif (CNN).

Amélioration du contraste par CLAHE

L'image est ensuite convertie de RGB vers LAB (Luminosité, canal A vert/rouge, canal B bleu/jaune), une représentation plus adaptée à l'ajustement du contraste. Seul le canal de luminance (L) est traité avec la méthode CLAHE (Contrast Limited Adaptive Histogram Equalization), via `cv2.createCLAHE`. La luminance améliorée est ensuite recombinée avec les canaux A et B, et l'image est reconvertie en RGB.

Cette technique permet de rehausser les détails fins (comme les micro-veines ou lésions) dans des zones d'ombre ou peu contrastées, sans surexposer les régions déjà claires. Elle est particulièrement adaptée aux images médicales à fort gradient local.

Normalisation des pixels

Enfin, les valeurs des pixels sont normalisées dans l'intervalle [0,1] en divisant par 255.0 (`img.astype('float32') / 255.0`).

Architecture CNN

Objectif du modèle

Notre objectif est de concevoir un modèle de réseau de neurones convolutif (CNN) capable de classer automatiquement les images de fond d'œil selon qu'elles montrent des signes de rétinopathie diabétique ou non. Ce réseau est inspiré du modèle proposé par Abed et al. (2020) [15], mais nous l'avons implémenté en Keras avec quelques ajustements pour l'adapter à notre environnement de travail et à nos contraintes techniques.

Architecture détaillée

Notre modèle suit une architecture séquentielle classique, enchaînant des couches convolutives, de normalisation, d'activation, de sous-échantillonnage (pooling), puis des couches entièrement connectées.

Layer	Configuration	Description
Input	Shape = (IMG_SIZE,	Couche d'entrée (image RGB)

	IMG_SIZE, 3)	
conv_1	Filter size = 3x3/Filters = 8/Stride = 1,1/Padding = ‘same’	Couche de convolution 1
batchnorm_1	Epsilon = 1e-5	Normalisation 1
relu_1	Activation = ReLU	Fonction d’activation 1
maxpool_1	Pool size = 2x2/Stride = 2,2	MaxPooling 1
conv_2	Filter size = 3x3/Filters = 16/Stride = 1,1/Padding = ‘same’	Couche de convolution 2
batchnorm_2	Epsilon = 1e-5	Normalisation 2
relu_2	Activation = ReLU	Fonction d’activation 2
maxpool_2	Pool size = 2x2Stride = 2,2	MaxPooling 2
conv_3	Filter size = 3x3/Filters = 32 Stride = 1,1/Padding = ‘same’	Couche de convolution 3
batchnorm_3	Epsilon = 1e-5	Normalisation 3
relu_3	Activation = ReLU	Fonction d’activation 3
maxpool_3	Pool size = 2x2/Stride = 2,2	MaxPooling 3
flatten	—	Aplatissement des features
fc_1	Units = 64/Activation = ReLU	Couche dense
dropout	Probability = 0.3	Régularisation

fc_2	Units = 2Activation = Softmax	Couche de sortie
optimizer	SGDLR = 0.01Momentum = 0.9	Optimisation
loss	Categorical Crossentropy	Fonction de coût
metrics	Accuracy	Métrique

Tab 4. Résumé des paramètres et hyperparamètres de notre modèle

Conclusion sur le choix d'architecture

Notre modèle s'inscrit clairement dans la continuité du modèle de Abed et al. tout en étant adapté à l'environnement Keras. Il conserve la même philosophie de légèreté : un CNN peu profond mais suffisant pour détecter les anomalies visibles dans les images de fond d'œil. Grâce à une architecture sobre et une implémentation optimisée, ce modèle est bien adapté aux datasets DiaretDB0 et DiaretDB1 et peut servir de base à des extensions futures (multiclasse, localisation des lésions, etc.).

Entraînement & évaluation

Objectif expérimental

L'objectif de notre expérimentation est d'évaluer les performances du modèle CNN que nous avons reconstruit en Python (Keras) en le testant sur trois bases de données publiques largement utilisées pour la détection de la rétinopathie diabétique : DIARETDB0, DIARETDB1 et DRIMDB. Ces bases contiennent des images de fond d'œil, annotées selon la présence ou non de signes cliniques de la maladie.

Chargement et prétraitement des données

Pour chaque base de données, nous avons utilisé une fonction `load_dataset_from_drive()` qui renvoie :

- x : les images RGB, prétraitées (cf. section précédente),
- y : les labels binaires indiquant si l'image est saine ou malade.

Les labels sont ensuite transformés en format one-hot encoding via `to_categorical()` pour être compatibles avec la fonction de perte `categorical_crossentropy`.

Séparation entraînement / test

Les données sont divisées selon un split de 80% pour l'entraînement et 20% pour le test à l'aide de `train_test_split()`. Lorsque les deux classes (sain/malade) sont présentes, la séparation est stratifiée pour conserver les proportions entre classes.

Cette étape garantit que le modèle est entraîné sur des images qu'il n'a jamais vues, et que l'évaluation est représentative de sa capacité de généralisation.

Évaluation et métriques

Après l'entraînement, le modèle est évalué sur l'ensemble de test avec `model.evaluate()`, fournissant l'accuracy (précision) qui est la proportion d'images correctement classées.

Nous générons également un rapport de classification détaillé (`classification_report`) qui fournit la précision, le rappel et le score F1 pour chaque classe (sain / malade), même si certaines classes sont rares ou absentes dans les prédictions (zero_division=0).

Comparaison avec le papier

Nous avons ensuite comparé nos scores finaux aux scores rapportés par le papier de référence :

Dataset	Nombre d'epochs	Validation accuracy Abed et al. (2020)	Validation accuracy projet
DIARETDB0	1	62,67%	84.6%
	13	100%	84.6%
	20	100%	84.62%
DIARETDB1	1	57,9%	100%
	13	99,89%	100%

	20	99,1%	100%
DRIMDB	1	68%	40.91%
	13	95,1%	43.2%
	20	100%	43.2%

Tab 5. Résumé des résultats obtenus par datasets et nombre d'epochs

Interprétation

L'analyse détaillée des performances de notre modèle, mis en regard de l'étude de référence d'Abed et al. (2020), révèle plusieurs phénomènes importants liés à la nature des données et à la méthodologie d'apprentissage.

Les scores élevés obtenus sur ces deux bases de données (84.6% pour DiaretDB0 et 100% pour DiaretDB1) doivent être interprétés avec prudence.

Sur DiaretDB0, la précision obtenue (84.6%) correspond exactement à la proportion d'images malades dans le dataset (110 malades sur 130). Le modèle a convergé vers une stratégie "naïve" consistant à prédire systématiquement la classe majoritaire ("Malade"). Il maximise ainsi sa précision globale sans pour autant discriminer les caractéristiques visuelles de la pathologie, ce qui se traduit par un rappel de 0 pour la classe "Sain".

	precision	recall	f1-score	support
Sain	0.00	0.00	0.00	4
Malade	0.85	1.00	0.92	22

Fig 2. Métriques du CNN pour le dataset DiaretDB0

Sur DiaretDB1, le résultat parfait de 100% est dû à l'absence quasi-totale d'images saines dans le jeu de test. Le modèle, ayant adopté le même biais majoritaire que pour DiaretDB0, réalise un sans-faute par défaut, ce qui ne garantit pas sa robustesse en conditions réelles pour distinguer un cas sain d'un cas pathologique.

	precision	recall	f1-score	support
Sain	0.00	0.00	0.00	0
Malade	1.00	1.00	1.00	18

Fig 3. Métriques du CNN pour le dataset DiaretDB1

Le résultat sur DRIMDB (43.2%) est particulièrement instructif. Contrairement aux deux autres bases, ce dataset est annoté selon des critères de **qualité d'image** (Bonne/Mauvaise/Outlier) et non de diagnostic médical. L'échec du modèle à reproduire les performances élevées de l'article (97.5%) suggère une incohérence dans la méthodologie originale.

	precision	recall	f1-score	support
Sain	1.00	0.04	0.08	25
Malade	0.44	1.00	0.61	19

Fig 4. Métriques du CNN pour le dataset DRIMDB

L'écart significatif entre nos résultats et ceux de l'article suggère que la seule architecture CNN, sans techniques additionnelles de rééquilibrage (comme la Data Augmentation intensive ou des fonctions de perte pondérées), est vulnérable aux biais statistiques inhérents aux petits datasets médicaux déséquilibrés. Notre étude démontre qu'une reproduction stricte du papier ne suffit pas à valider le modèle, soulignant la nécessité de données plus robustes et plus rigoureuses pour éviter le sur-apprentissage de la classe dominante et garantir une véritable capacité de diagnostic.

Outils et environnement technique

Pour ce projet, nous avons choisi d'utiliser Python comme langage principal, en raison de sa popularité dans le domaine de l'intelligence artificielle et de sa large compatibilité avec les bibliothèques de deep learning. Le modèle a été implémenté avec TensorFlow/Keras, une bibliothèque open-source puissante et intuitive, qui permet de construire et d'entraîner

facilement des réseaux de neurones convolutifs. L'entraînement a été réalisé dans un environnement Jupyter Notebook ou Google Colab, permettant une exécution interactive, la visualisation des résultats en temps réel et l'utilisation d'accélérateurs matériels comme les GPU. Pour la gestion et la visualisation des performances, nous avons utilisé des outils tels que matplotlib pour les courbes d'apprentissage, et scikit-learn pour générer des métriques comme les rapports de classification et les matrices de confusion. Enfin, les jeux de données ont été récupérés depuis Google Drive pour faciliter leur chargement dans Colab et leur réutilisation sur plusieurs sessions.

Extensions possibles et améliorations

Classification selon le label "hémorragies"

Cette partie du code se trouve dans le notebook nommé "CNN_Classification selon le label "hémorragies".ipynb".

Contexte

Dans un premier temps, nous avons reproduit l'approche classique largement utilisée dans la littérature, à savoir une classification binaire "sain" / "pas sain" sur le dataset DIARETDB0. Cette méthode consiste à attribuer une étiquette positive à toute image présentant au moins une lésion (peu importe son type) et une étiquette négative aux images supposément "saines".

Cependant, ce paradigme s'est rapidement révélé problématique. Le dataset DIARETDB0 contient très peu d'images réellement saines. La grande majorité des 130 images présentent au moins une lésion annotée.

En conséquence, le modèle est fortement biaisé par un déséquilibre des classes, ce qui fausse l'apprentissage et l'interprétation des performances. Un bon score peut refléter un simple apprentissage du biais du dataset, plutôt qu'une véritable capacité à détecter les signes de rétinopathie.

Pour contourner ce biais et rendre la tâche plus rigoureuse, nous avons choisi de reformuler le problème comme une classification binaire de la présence d'hémorragies uniquement.

- Cette lésion est clairement annotée dans les fichiers .res, ce qui permet de construire un label précis et fiable.
- Elle est présente dans 29 images sur 130, ce qui constitue une base exploitable pour un apprentissage supervisé.
- Les hémorragies ont une signature visuelle marquée, ce qui correspond bien à la capacité d'un CNN à apprendre des patterns texturaux ou chromatiques.

Mise en place du code

Nous avons repris exactement le même pipeline fait dans la classification 'sain' / 'non sain' par Abed et al. (2020) [15] et repris par notre groupe plus haut (cf. explication du code dans Architecture CNN). C'est pourquoi nous ne présenterons que les résultats obtenus.

Entraînement & évaluation

Nombre d'epochs	Accuracy	Loss
1	73.08%	0.69
13	**76.92%**	**0.59**
20	69.23%	0.67

Tab 1. Résultat de l'expérimentation sur le label "hémorragie" du dataset DiaretDB0 par nombre d'epochs

Lorsque le modèle est entraîné pendant seulement 1 epoch, il atteint **une accuracy de 73.08% avec une loss de 0.69**. Ce résultat reflète un modèle qui débute son apprentissage. Il n'a pas encore eu le temps de réellement comprendre les motifs présents dans les données, et ses prédictions restent peu confiantes. La loss élevée, proche de celle d'un modèle qui devinerait au hasard, en est un bon indicateur. L'accuracy relativement élevée peut quant à elle s'expliquer par un déséquilibre des classes : prédire systématiquement la classe majoritaire permet d'atteindre un taux de réussite correct, sans réelle compréhension des données.

En poursuivant l'entraînement jusqu'à 13 epochs, les performances du modèle s'améliorent nettement. **L'accuracy monte à 76.92%, tandis que la loss chute à 0.59**. Cela

signifie que le modèle a mieux appris à distinguer les classes et qu'il produit des prédictions plus sûres. La perte plus faible montre qu'il commet moins d'erreurs. C'est ici que le modèle semble atteindre son meilleur équilibre entre apprentissage et généralisation : il a eu le temps de s'adapter aux données sans pour autant tomber dans l'excès.

En revanche, lorsque l'entraînement est prolongé jusqu'à 20 epochs, la qualité des prédictions se détériore. **L'accuracy retombe à 69.23% et la loss remonte à 0.67**. Cela indique que le modèle a probablement commencé à surapprendre les données d'entraînement : il mémorise trop les exemples vus, au point de perdre sa capacité à généraliser sur des données nouvelles. Cette dégradation est typique du surapprentissage, et elle souligne l'importance d'un arrêt anticipé lorsque les performances sur les données de test ou de validation commencent à se dégrader.

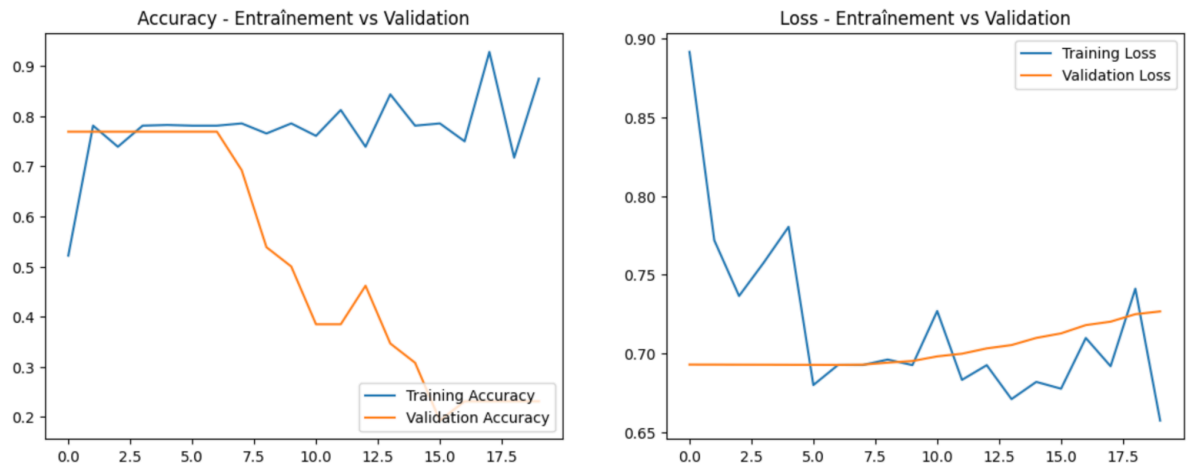

Fig 5. Évolution de l'accuracy et de la perte selon le dataset pour 20 epochs

Utilisation de l'IA

Dans le code

Nous avons utilisé l'intelligence artificielle (ChatGPT, Gemini) dans notre code principalement pour mieux comprendre la maladie évoquée dans le papier, la rétinopathie diabétique, ainsi que pour identifier et reproduire les grandes étapes de construction du modèle proposées par les auteurs. Cette implémentation nous a permis de clarifier le fonctionnement du réseau convolutif décrit dans l'article, de visualiser concrètement les phases de prétraitement, d'apprentissage et d'évaluation, et de mieux saisir la logique que nous devons coder.

Dans le rapport

ChatGPT a été utilisé dans ce rapport à des fins de relecture, afin de corriger d'éventuelles fautes d'orthographes et la syntaxe des phrases. Nous lui avons demandé de corriger chaque paragraphe avec le prompt suivant "Peux-tu corriger les fautes d'orthographes éventuellement présentes dans ce paragraphe?" et de vérifier la syntaxe avec le prompt suivant "Peux-tu corriger la syntaxe de ce paragraphe ?".

Il nous a aussi permis de rendre des parties plus fluides en lui demandant de réorganiser les idées pour que ce soit plus facilement lisible avec le prompt suivant : "Comment mieux organiser les idées évoquées dans ce paragraphe ?".

Conclusion

Ce projet avait pour objectif principal la reproduction fidèle et l'évaluation critique du système de détection de la Rétinopathie Diabétique (RD) basé sur un Réseau de Neurones Convolutifs (CNN) et le prétraitement CLAHE, tel que proposé par Abed et al. (2020) [15].

Bien que nous ayons réussi à reproduire les scores élevés de l'étude de référence sur DIARETDB0 (84.6%) et DIARETDB1 (100%), l'analyse critique a révélé que ces résultats étaient trompeurs. Le modèle a en réalité convergé vers une stratégie "naïve" consistant à prédire systématiquement la classe majoritaire en raison du déséquilibre inhérent aux petits datasets médicaux. L'échec observé sur DRIMDB (43.2%) a, de plus, mis en lumière l'incohérence méthodologique d'entraîner un modèle de diagnostic sur des labels de qualité d'image plutôt que sur des critères cliniques.

Pour garantir une évaluation fiable de la capacité du modèle à apprendre, nous avons reformulé le problème en une classification binaire de la présence ou absence d'hémorragies uniquement. Cette extension a permis de démontrer une véritable capacité d'apprentissage du CNN sur une signature visuelle spécifique, atteignant une précision optimale de 76.92% à 13 epochs. Cette expérience a également souligné l'importance d'un arrêt anticipé de l'entraînement pour prévenir le surapprentissage, qui dégrade les performances après 13 epochs.

En conclusion, notre travail valide la pertinence technique de l'architecture CNN, mais met surtout en évidence la vulnérabilité des modèles aux biais statistiques. Le succès d'un système d'IA dans un cadre clinique dépend non seulement de la qualité de son architecture, mais fondamentalement de la rigueur du protocole de préparation des données et de la justesse de la formulation du problème d'apprentissage.

Bibliographie

[1] Tahira Nazir, Aun Irtaza, Zain Shabbir, Ali Javed, Usman Akram, Muhammad Tariq Mahmood, Diabetic retinopathy detection through novel tetragonal local octa patterns and extreme learning machines, Artificial Intelligence in Medicine, Volume 99, 2019, 101695, ISSN 0933-3657, https://doi.org/10.1016/j.artmed.2019.07.003.

[2] John Elflein, Diabetes - Statistics & Facts, Health & Pharmaceuticals , Sep 12, 2019, https://www.statista.com/topics/1723/diabetes/

[3] Wang W, Lo ACY. Diabetic Retinopathy: Pathophysiology and Treatments. Int J Mol Sci. 2018;19(6):1816. Published 2018 Jun 20. doi:10.3390/ijms19061816.

[4] S.A.G. Naqvi, M.F. Zafar, I. ul Haq, Referral system for hard exudates in eye fundus, Comput. Biol. Med. 64 (2015) 217–235, http://dx.doi.org/10.1016/j.compbiomed.2015.07.003.

[5] W.M.D.W. Zaki, M.A. Zulkifley, A. Hussain, W.H.W.A. Halim, N.B.A. Mustafa,L.S. Ting, Diabetic retinopathy assessment: towards an automated system, Biomed. Signal Process. Control 24 (2016) 72–82.

[6] A. Sopharak, B. Uyyanonvara, S. Barman, T.H. Williamson, Automatic detection of diabetic retinopathy exudates from non-dilated retinal image using mathematical morphology methods, Comput. Med. Imaging Graph. 32(8) (2008) 720–727.

[7] NIDHAL K. EL ABBADI, ENAS HAMOOD AL- SAADI, Automatic Early Diagnosis of Diabetic Retinopathy Using Retina Fundus Images, EUROPEAN ACADEMIC RESEARCH, Vol. II, Issue 9/ December 2014

[8] L. Giancardo, F. Meriaudeau, T.P. Karnowski, Y. Li, S. Garg, K.W. Tobin Jr., E.Chaum, Exudate-based diabetic macular edema detection in fundus images using publicly available datasets, Med. Image Anal. 16 (1) (2012) 216–226.

[9] C.I. Sánchez, M. García, A. Mayo, M.I. López, R. Hornero, Retinal image analysis based on mixture models to detect hard exudates, Med. Image Anal. 13 (4)(2009) 650–658.

[10] B_alint BORSOS, L_aszl_o NAGY, David ICL_ANZAN and L_aszl_o SZIL_AGYI, " Automatic detection of hard and soft exudates from retinal fundus images", Acta Univ. Sapientiae, Informatica 11, 1 (2019) 65{79}.

[11] S. Bourouis, A. Zaguia, N. Bouguila, Hybrid statistical framework for diabetic retinopathy detection,in: International Conference Image Analysis and Recognition, Springer, 2018, pp. 687–694.

[12] P. Prentasic, S. Loncaric, Detection of exudates in fundus photographs using convolutional neural networks, 2015 9th International Symposium on Image and Signal Processing and Analysis (ISPA) (2015) 188–192, http://dx.doi.org/10.1109/ISPA.2015.7306056.

[13] Parham Khojasteh, Behzad Aliahmad, Dinesh Kant Kumar , A novel color space of fundus images for automatic exudates detection. Biomed. Signal Process. Control. 49: 240-249 (2019)

[14] P. Khojasteh, L.A.P. Júnior, T. Carvalho, E. Rezende, B. Aliahmad, J.P. Papa, D.K.Kumar, Exudate detection in fundus images using deeply-learnable features, Comput. Biol. Med. 104 (2019) 62–69, http://dx.doi.org/10.1016/j.compbiomed.2018.10.031.

[15] M.H. Abed, L.A.N. Muhammed, S.H. Toman, Diabetic Retinopathy Diagnosis based on Convolutional Neural Network, arXiv preprint arXiv:2008.00148, 2020. https://arxiv.org/abs/2008.00148.